Laboratório de Estrutura de Dados

Primeira versão do projeto da disciplina

Comparação entre os algoritmos de ordenação elementar

UNIVERSIDADE ESTADUAL DA PARAÍBA

CENTRO DE CIÊNCIAS E TECNOLOGIA

CIÊNCIA DA COMPUTAÇÃO

Lucas de Lucena Siqueira - 201080354

Daniel Xavier Brito de Araújo - 201080303

Ian Vasconcelos Bernardo - 201080044

Campina Grande
2022

1. Introdução

Este relatório corresponde ao relato dos resultados obtidos no projeto da disciplina de LEDA que tem foco no site AirBNB. Responsável por promover acomodações, sendo uma plataforma disruptiva no setor desde o lançamento. É apresentado um dataset que contém informações gerais como nome do dono, vizinhança, latitude, longitude, tipo do lugar, preço, avaliações, dentre outros atributos.

Foram realizadas algumas transformações e tratamento dos dados fornecidos no dataset, como as formatação da data para dd/MM/yyyy, e filtragem dos apartamentos que estavam acima ou abaixo do preço médio, sendo gerado para cada um desses tratamentos um arquivo .csv diferente (todos esses arquivos podem ser encontrados no diretório “airBnb-dataAnalyses\src\main\resources\csvFiles”)

Também foi proposto o desenvolvimento de ordenações a partir do uso de alguns algoritmos de ordenação, sendo eles o Counting Sort, Heap Sort, Insertion Sort, Merge Sort, Quick Sort, Quick Sort Mediana de 3 e por fim o Selection Sort . Todas as ordenações tomaram como parâmetro para a execução no médio, melhor e pior caso os seguintes campos fornecidos no dataset:

- Listagens pelo nomes dos lugares (campo name) em ordem alfabética;
- Listagens pelos preços (campo price) dos lugares do menor para o maior;
- Listagens pelos número de reviews (campo number_of_reviews) dos lugares do menor para o maior;
- Listagens pela data do último review (campo last_review) dos lugares do mais recente para o mais antigo.

Cada algoritmo foi testado com a mesma base de dados e também nas mesmas condições de ambiente. Quanto às ferramentas utilizadas, a implementação foi feita a partir da linguagem JAVA e a fim de monitorar o consumo de memória foi utilizado o VisualVM.

Após a execução do projeto foi possível observar as diferenças presentes em cada um dos algoritmos de ordenação utilizados, tanto no consumo de memória como principalmente no tempo de execução. Todas as análises serão apresentadas no decorrer do relatório.

2. Descrição geral sobre o método utilizado

Para a realização dos procedimentos de teste, o projeto foi organizado em alguns passos bem definidos que são personificados para cada uma das ordenações. O primeiro passo foi utilizar o arquivo gerado anteriormente com o tratamento das datas (“listings_review_date.csv”) para a instanciação dos dos apartamentos apresentados. Após os objetos terem sido instanciados o seguimento lógico utilizado foi referente à indicação dos processos de ordenação com a utilização de cada um dos algoritmos propostos e também dos parâmetros de ordenação definidos.

Para o processo de ordenação, os algoritmos foram escritos no package “ordenationAlgorithms”. Com os algoritmos já definidos, foram criados métodos específicos para cada uma das ordenações, presentes no package “ordenationMethods”, sendo que cada método tem o mesma lógica de funcionamento procedural, que seria definida nos seguintes passos:

- Ordenar os dados com o médio caso capturando o tempo de execução do procedimento e criando o arquivo .csv referente a essa ordenação.

- Ordenar os dados com o melhor caso capturando o tempo de execução do procedimento e criando o arquivo .csv referente a essa ordenação.

- Ordenar os dados com o pior caso capturando o tempo de execução do procedimento e criando o arquivo .csv referente a essa ordenação.

Vale ressaltar que todos os arquivos gerados se encontram no diretório “airBnb-dataAnalyses\src\main\resources\ordenatedCsvFiles”.

Descrição do ambiente de testes

- Processador AMD Ryzen 5 1600x (6 núcleos e 12 threads)
- Placa de vídeo NVIDEA GTX 1050TI 4GB GDDR5
- Memória RAM 16GB DDR4 2800MHz (2x8)
- Sistema Operacional Windows 10 Pro

3. Resultados e Análise

Resultados dos testes usando gráficos

As primeiras análises são referentes ao consumo de memória de cada algoritmo tendo como base cada um dos parâmetros de ordenação. Segue abaixo os gráficos obtidos com o auxílio do VisualVM para monitorar o consumo de memória dos algoritmos.

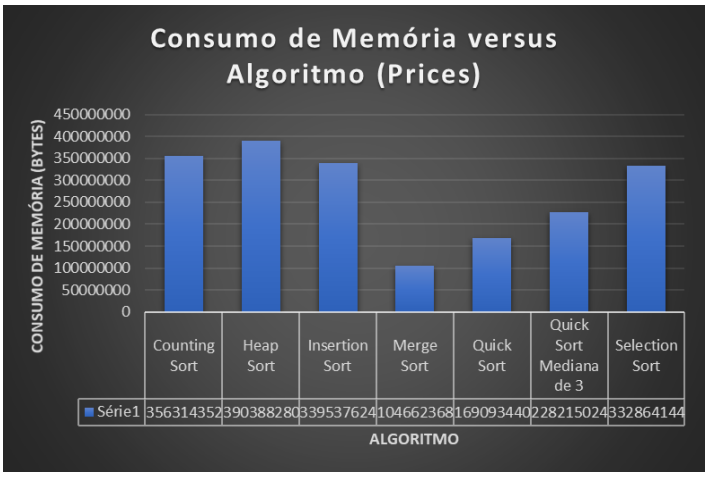

(Gráfico 01)

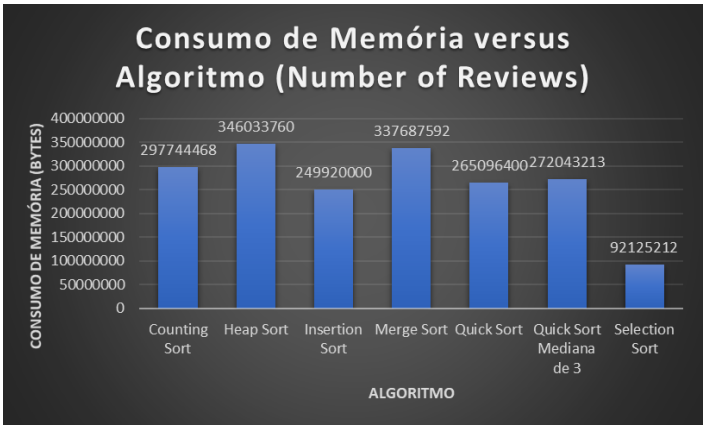

(Gráfico 02)

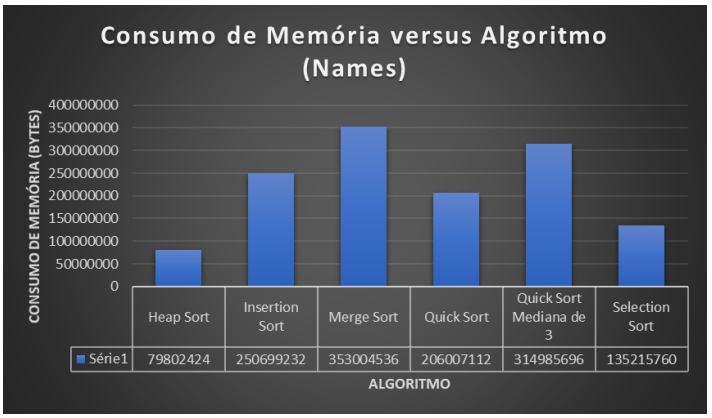

(Gráfico 03)

Já as análises a seguir se referem ao desempenho dos algoritmos de ordenação tendo em vista os tempos de execução de cada um para cada um dos parâmetros definidos previamente.

- **Parâmetro de ordenação: Prices**

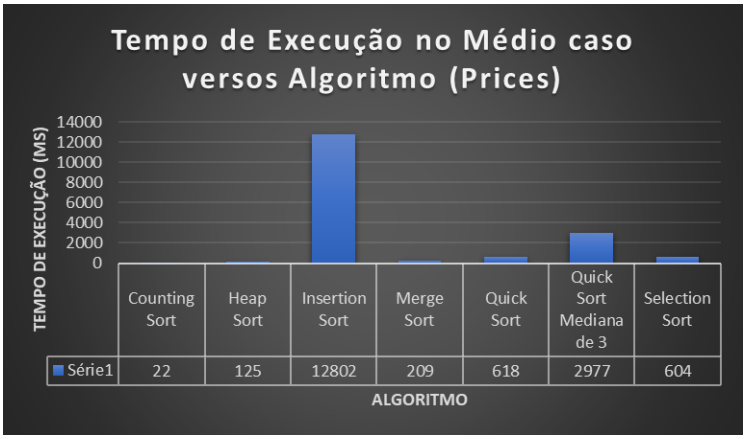

(Gráfico 04)

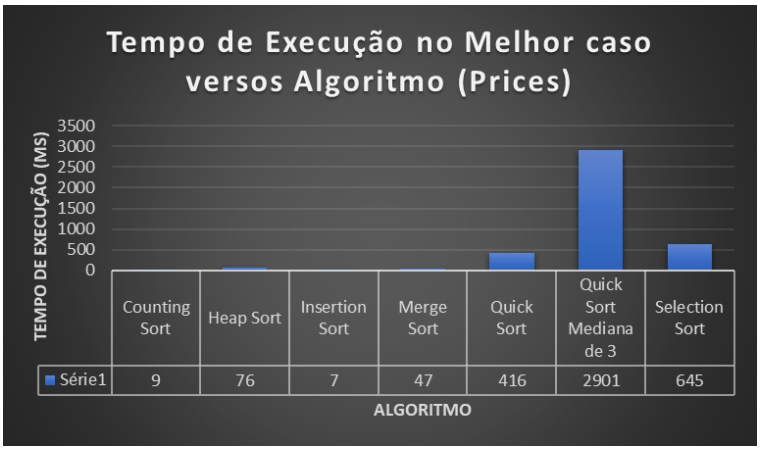

(Gráfico 05)

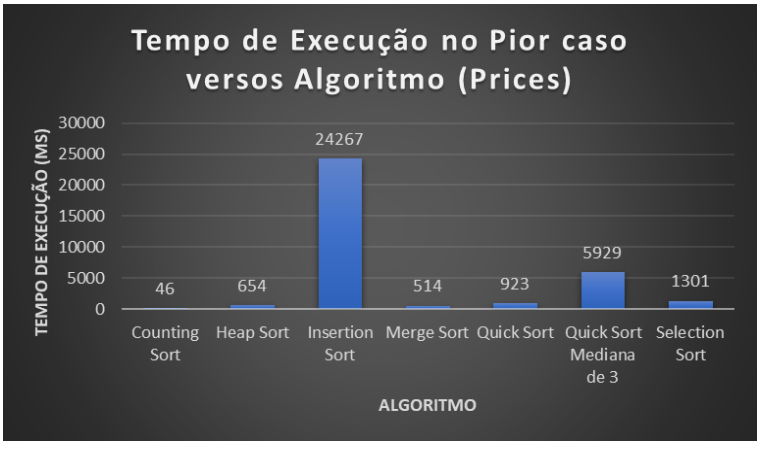

(Gráfico 06)

- **Parâmetro de ordenação: Number of Reviews**

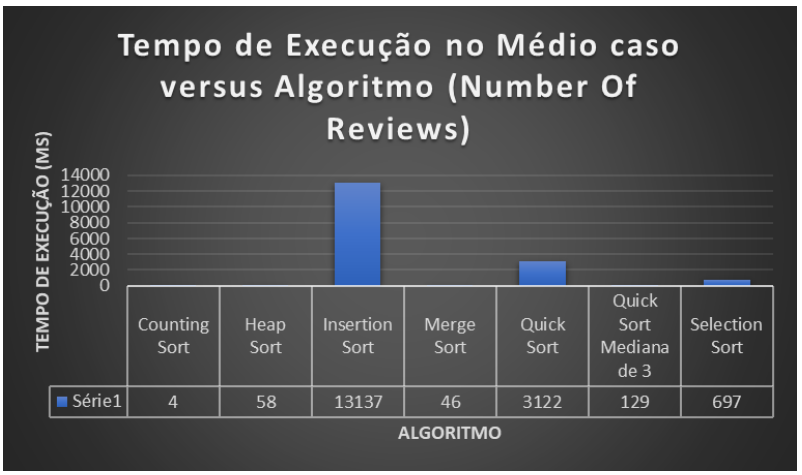

(Gráfico 07)

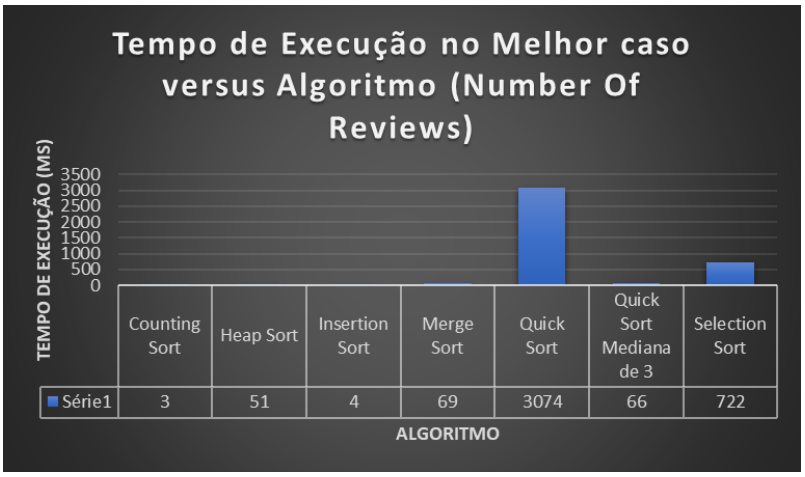

(Gráfico 08)

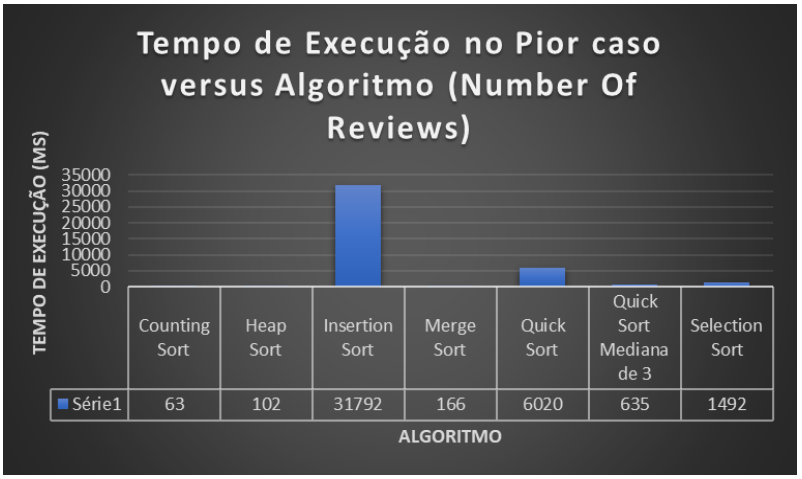

(Gráfico 09)

- **Parâmetro de ordenação: Names**

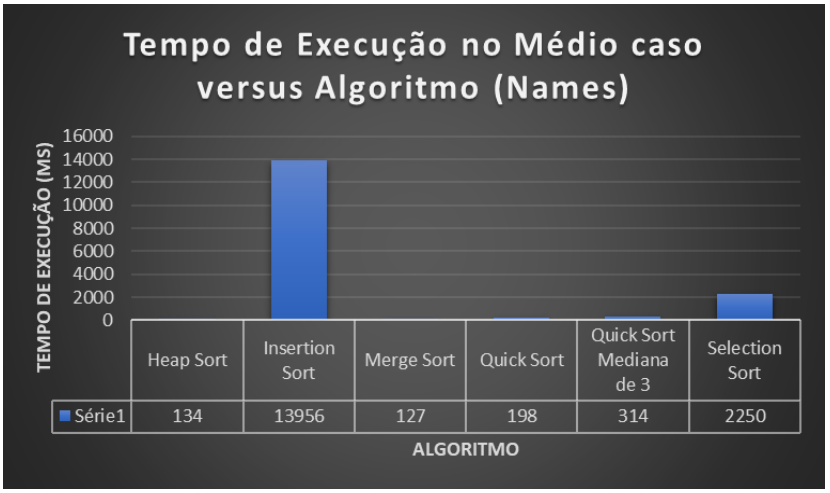

(Gráfico 10)

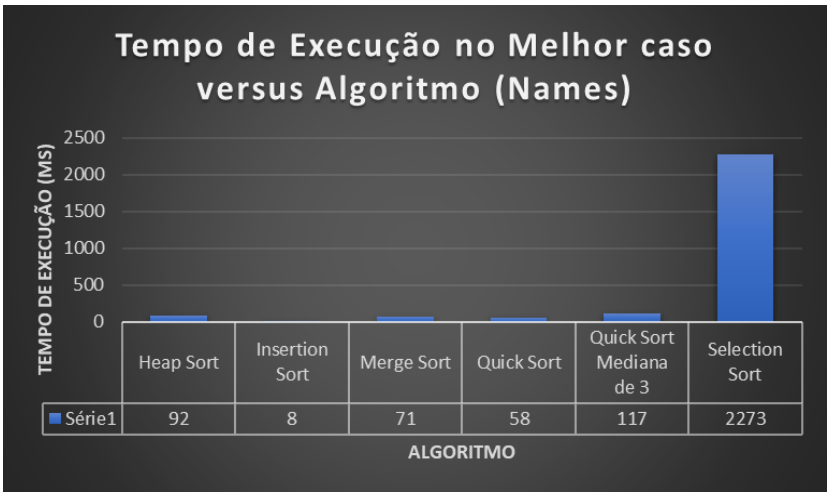

(Gráfico 11)

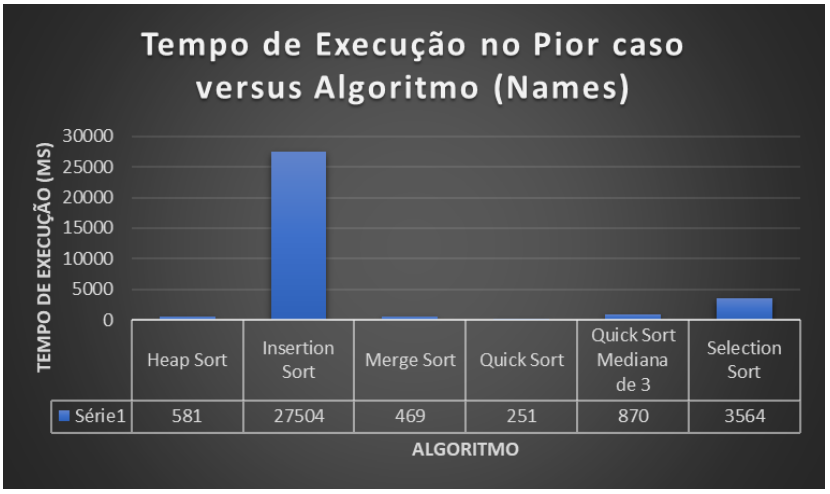

(Gráfico 12)

Por fim, podemos analisar os tempos de execução de cada algoritmo individualmente, levando em consideração cada um dos parâmetros pré-definidos.

- **Counting Sort**

É um algoritmo de ordenação com complexidade “O” para números pequenos, em que suas chaves podem assumir valores entre 0 e “M-1”. Caso tenha “k0” chaves de valor 0, ocupa as primeiras posições “k0” do vetor final: 0 a “k0-1”. A ideia básica de classificar por contagem é para cada entrada x, o número de elementos menor que i, que seria cada inteiro do vetor. Tais informações são utilizadas para colocar o elemento x na posição correta no array de saída.
Para o caso do Counting Sort, não é possível fazer a ordenação com parâmetros que sejam do tipo String, logo não foi possível fazer a ordenação com os parâmetros “Names” e “Last Review”.

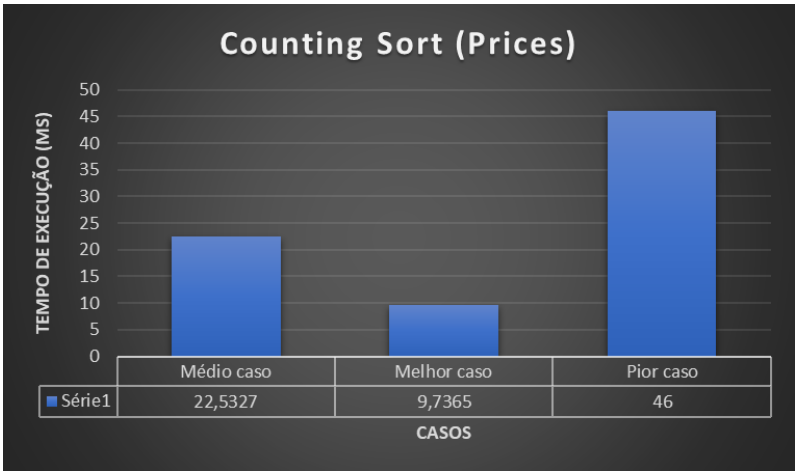

(Gráfico 13)

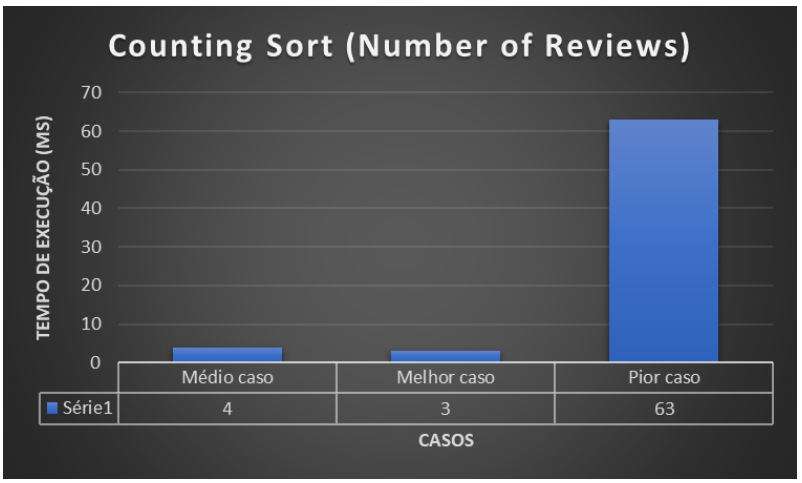

(Gráfico 14)

- **Heap Sort**

Ele tem um desempenho de tempo de execução muito bom em coleções ordenadas aleatoriamente, tem um bom uso de memória. Alguns algoritmos de classificação rápida têm um desempenho muito ruim no pior caso, tanto em termos de tempo de execução quanto de uso de memória. O Heap Sort funciona no local, e o tempo de execução do pior caso para classificar n elementos é 0(n lg n). Leia o logaritmo de base 2 (ou log) de "n". Para valores razoavelmente grandes de n, o termo log n é quase constante, portanto, o tempo de classificação é quase linear com o número de itens a serem classificados.

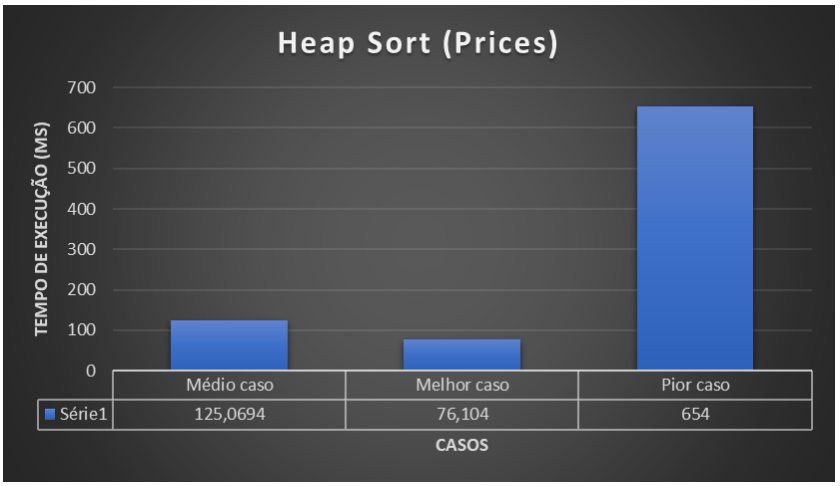

(Gráfico 15)

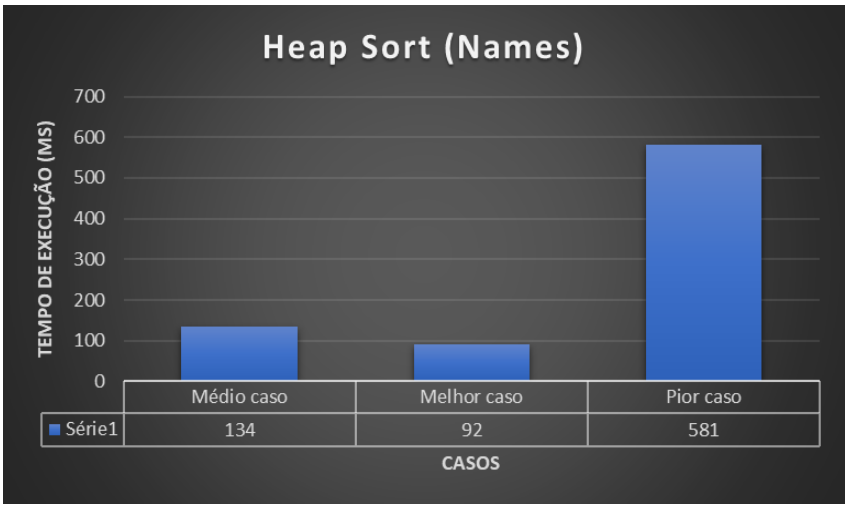

(Gráfico 16)

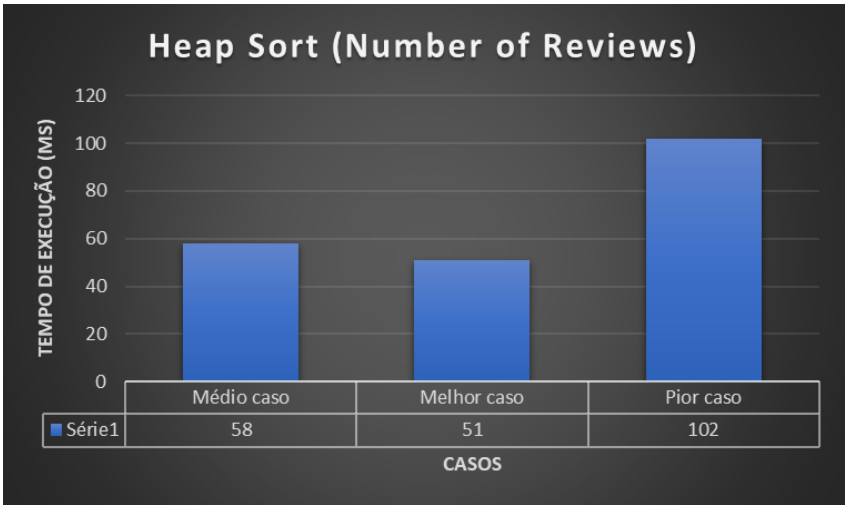

(Gráfico 17)

- **Insertion Sort**

A classificação por inserção é baseada na inserção ordenada. A ideia é executar essa rotina várias vezes para classificar o array. Para ser exato, se executarmos N−1 vezes a inserção ordenada em um array, o resultado será o mesmo. Então, vamos começar entendendo como funciona a inserção ordenada. A ordenação por inserção ou ordenação por inserção é um algoritmo de ordenação que, dada um array, constrói um array final, um elemento de cada vez, inserido um de cada vez. Percorra as posições do array, começando com o índice 1 (um). A cada nova posição você precisa inseri-la no lugar correto no subarray ordenado à esquerda daquela posição.

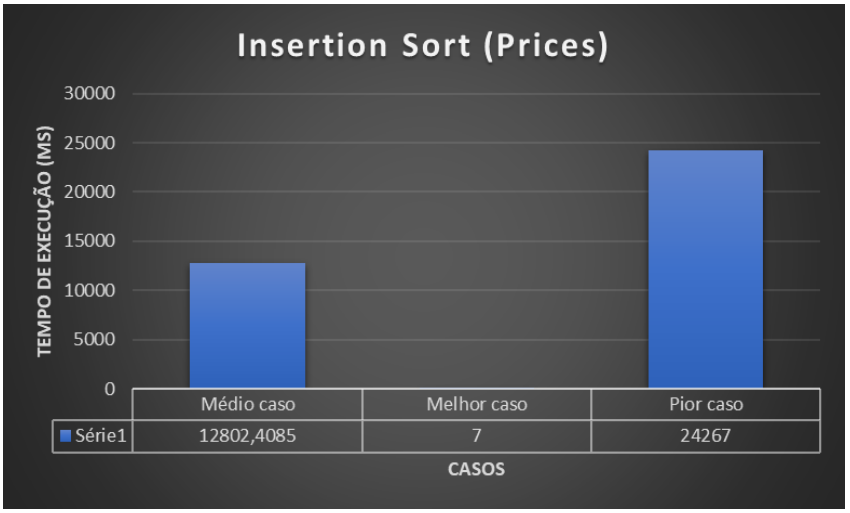

(Gráfico 18)

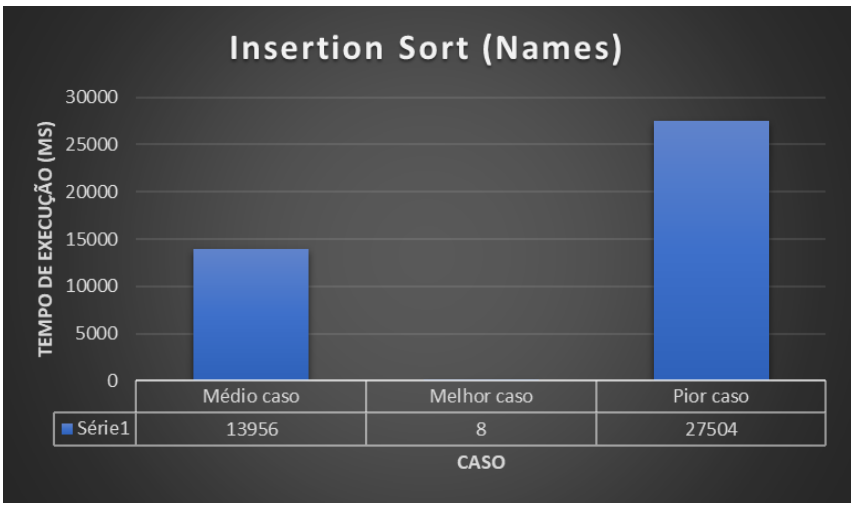

(Gráfico 19)

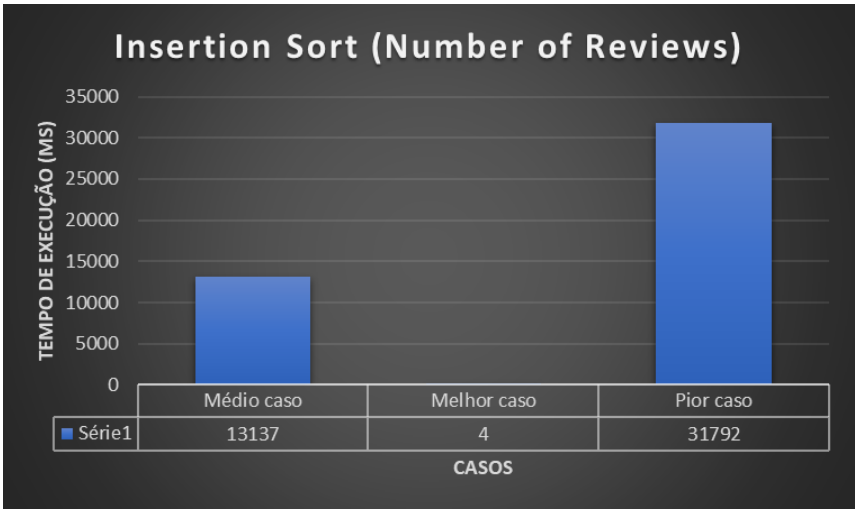

(Gráfico 20)

- **Merge Sort**

A ordenação por mesclagem é um algoritmo de ordenação de divisão e conquista eficiente. Se nossa tarefa é ordenar um array comparando seus elementos, então n∗log(n) é nosso limite inferior do ponto de vista assintótico. Ou seja, nenhum algoritmo de ordenação por comparação é mais rápido que n∗log(n). Formalmente, ambos são Ω(n∗log(n)). No caso do Merge Sort, uma característica importante é que sua eficiência é o melhor, o pior e a média dos casos de n∗log(n). Ou seja, não é apenas Ω(n∗log(n)) mas também Θ(n∗log(n)). Isso nos dá uma garantia de que a classificação funcionará, não importa como os dados estejam organizados na matriz. A operação de Merge Sort é baseada em uma rotina básica chamada merge.

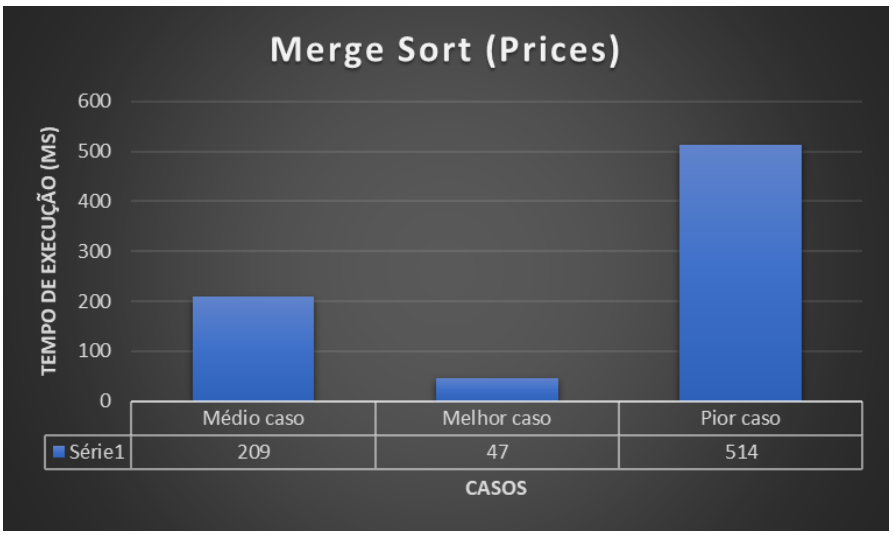

(Gráfico 21)

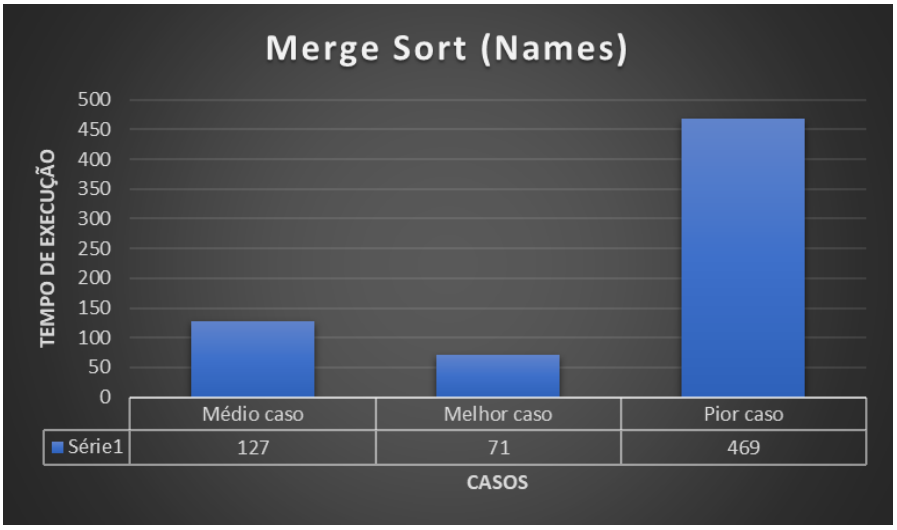

(Gráfico 22)

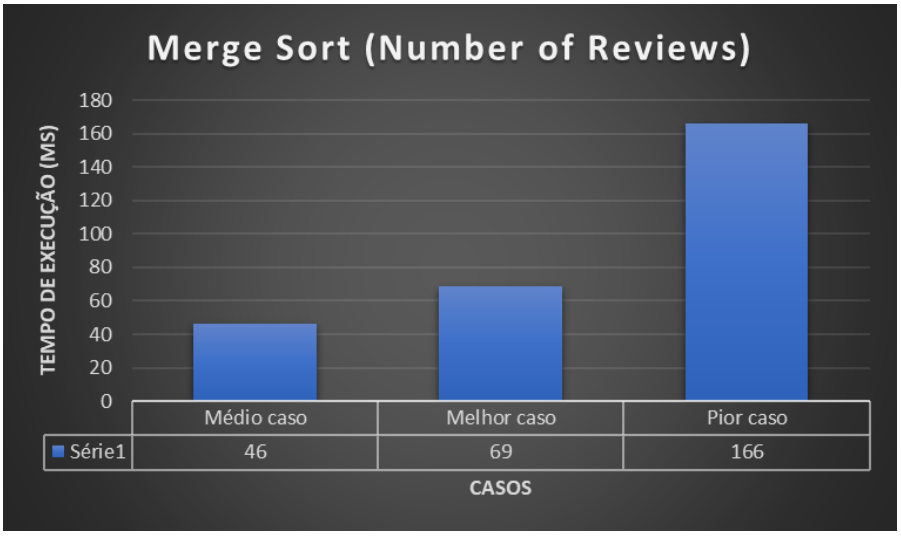

(Gráfico 23)

- **Quick Sort Mediana de 3**

A ideia do Quick Sort Mediana de 3 é selecionar três elementos de um vetor e tomar a mediana desses três elementos como pivô. Normalmente, os elementos no início, meio e fim do vetor são escolhidos ao calcular a mediana.

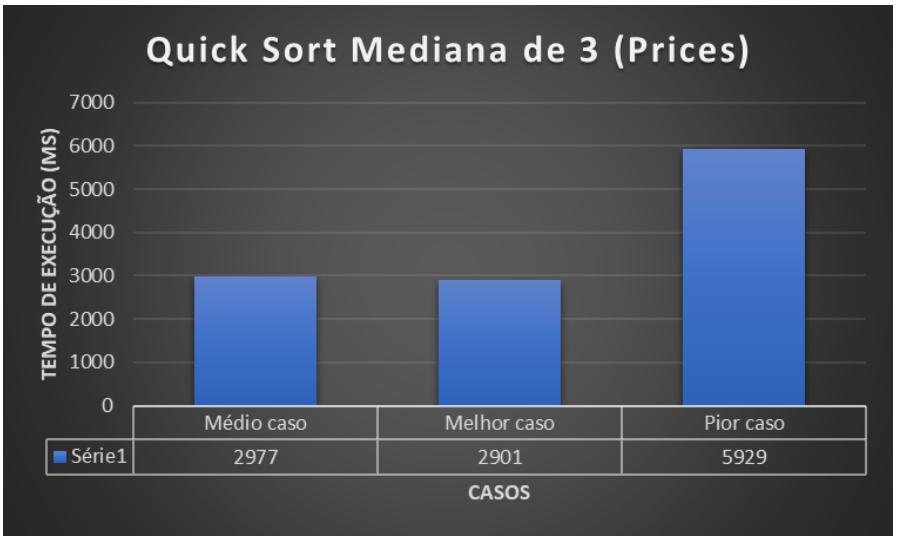

(Gráfico 24)

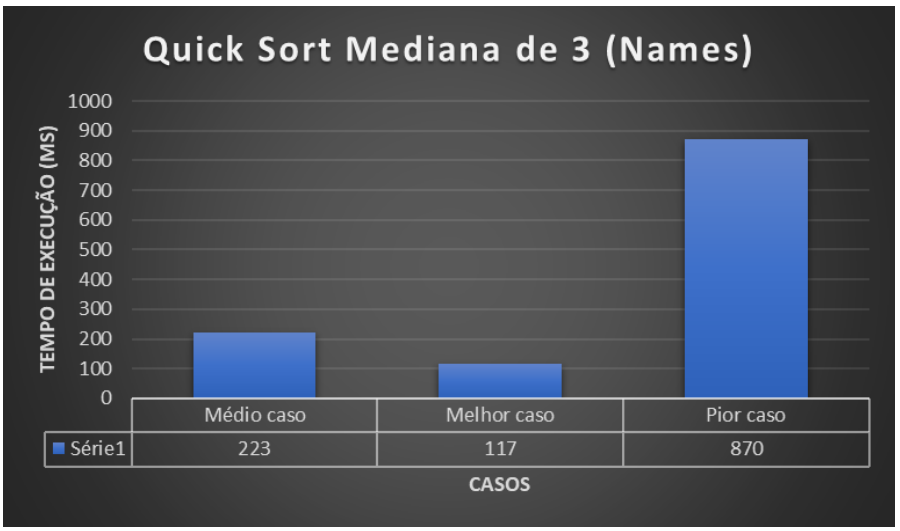

(Gráfico 25)

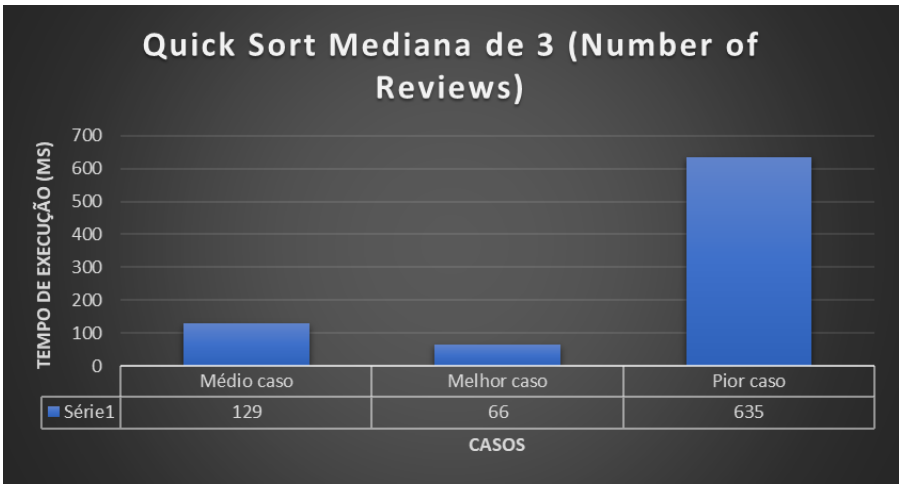

(Gráfico 26)

- **Quick Sort**

Quick Sort é um algoritmo de ordenação eficiente para e conquista. Embora seja da mesma classe de complexidade Merge Sort, Heap Sort ou Quick Sort, é o mais rápido deles, porque suas constantes são pequenas. No entanto, é importante salientar de antemão que, no pior caso, Quick Sort é O, enquanto Merge Sort e Heap Sort garantem n∗log(n) em todos os casos. A boa notícia é que existem estratégias simples que podemos minimizar o risco de acontecer o pior caso. A operação de Quick Sort é baseada em um fundamental cujo nome é particionamento. O particionamento consiste em escolher qualquer número presente no array, chamado pivô, e colocá-lo em uma posição tal que todos os elementos da esquerda sejam ou iguais e todos os elementos no canto superior direito.

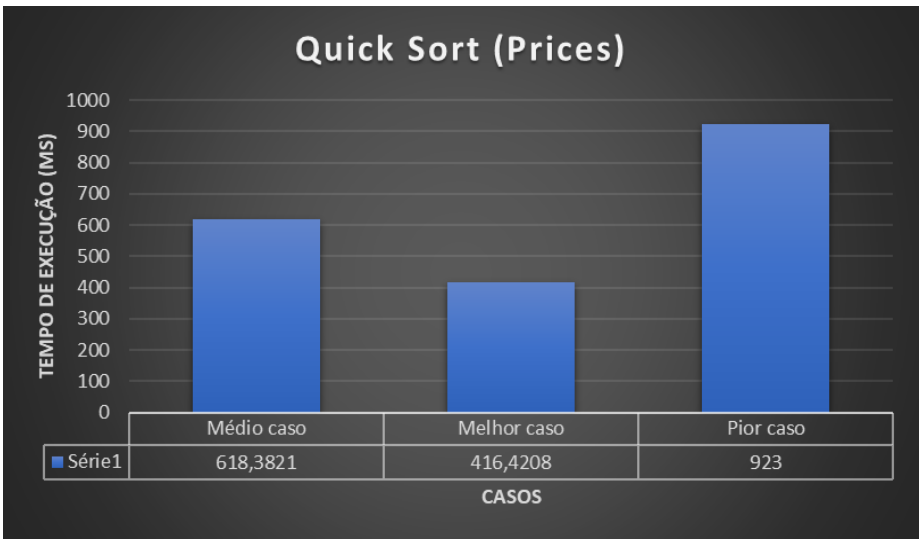

(Gráfico 27)

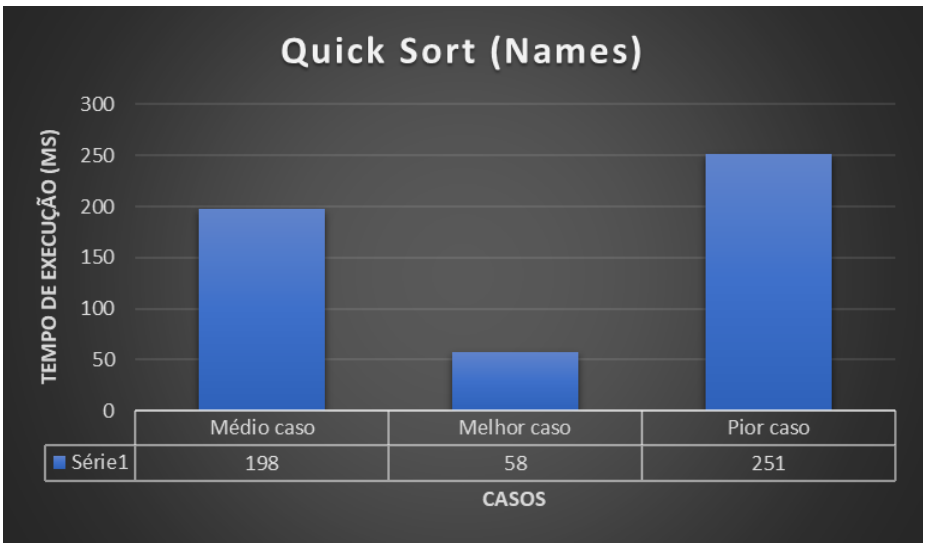

(Gráfico 28)

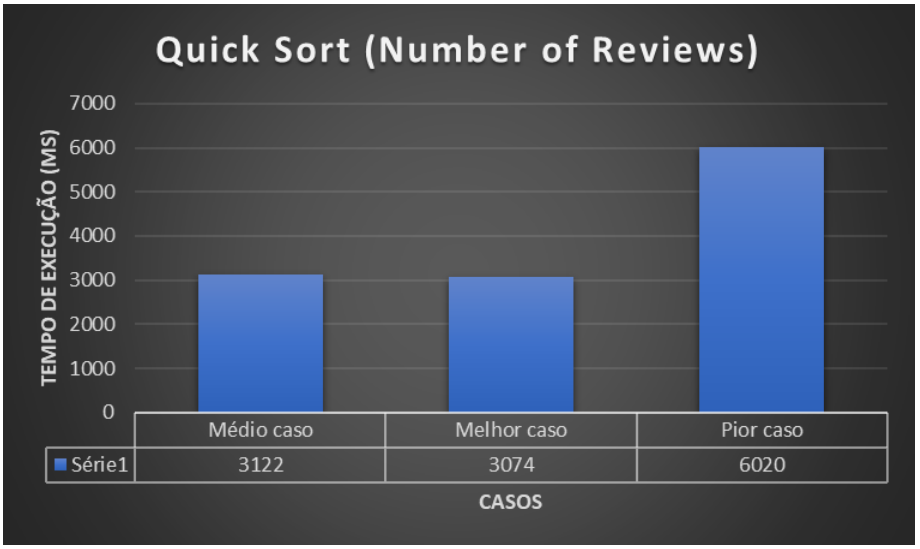

(Gráfico 29)

- **Selection Sort**

A classificação por seleção é um algoritmo de classificação no fato de sempre passar o menor do vetor para a primeira posição, depois o segundo valor pequeno para a segunda posição, e assim por diante com o restante n-1 elementos, até os dois últimos elementos.

(Gráfico 30)

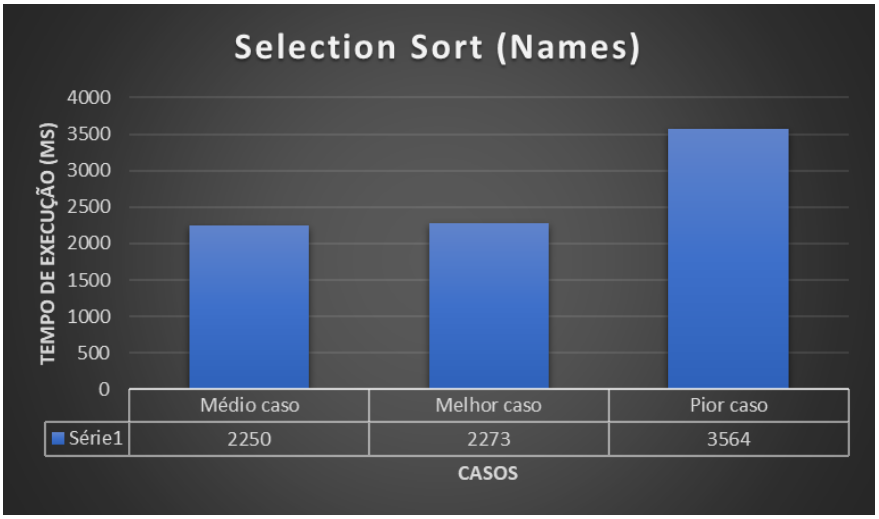

(Gráfico 31)

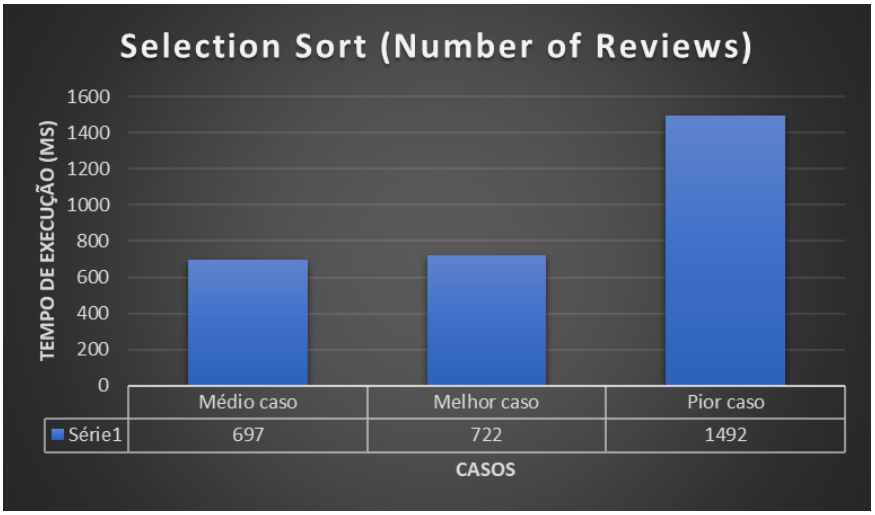

(Gráfico 32)

Após a análise gráfica apresentada é possível realizar algumas conclusões, dentre elas a mais assertiva se refere ao benefício do uso do Merge Sort, que se mostrou mais eficiente no quesito referente ao tempo de execução e o consumo de memória se mostrou dentro da média dos demais.